MIDTERM PROJECT · 2026

# 把 LINE 變成 會查資料的 待辦小幫手

同一個聊天視窗，兩種工作流：
「查 …」得到有來源的答案；其他訊息自動變成待辦。

本機推論　免 API 費用　附上來源

90 秒 Demo：查 玉山有多高 → 買牛奶



01 / PROBLEM

# 問題不是「沒有 AI」，是每天多做了幾次切換。

01

## 查資料要跳 App

在 LINE 看到問題，切到瀏覽器搜尋，看完再切回來。注意力被切成三段。

02

## 待辦散在聊天裡

「買牛奶」被後面的訊息洗掉；記事軟體又常常懶得開。

03

## 雲端 AI 有成本

逐字計費、需要 API key；敏感內容也不一定想送出門。

**主要使用者：常用 LINE 的學生與小型團隊　·　設計目標：不離開聊天室、答案可查證、沒有逐字費用**

# 一個入口，兩種工作流。

## 查 …

**先搜尋，再讓本機模型整理；答案最後附來源。**

新聞題走 Google News RSS；知識題走中文 Wikipedia。

**查 玉山有多高** → 3,950 公尺 + Wikipedia 來源
**查 今天台灣有什麼新聞** → 新聞摘要 + 媒體來源

## 記事情

**不是「查」開頭的訊息，直接寫進待辦。**

正式 LINE 版寫入 Google Sheet；展示頁寫入本機 todo.txt。

**買牛奶** → 已記錄到待辦：買牛奶

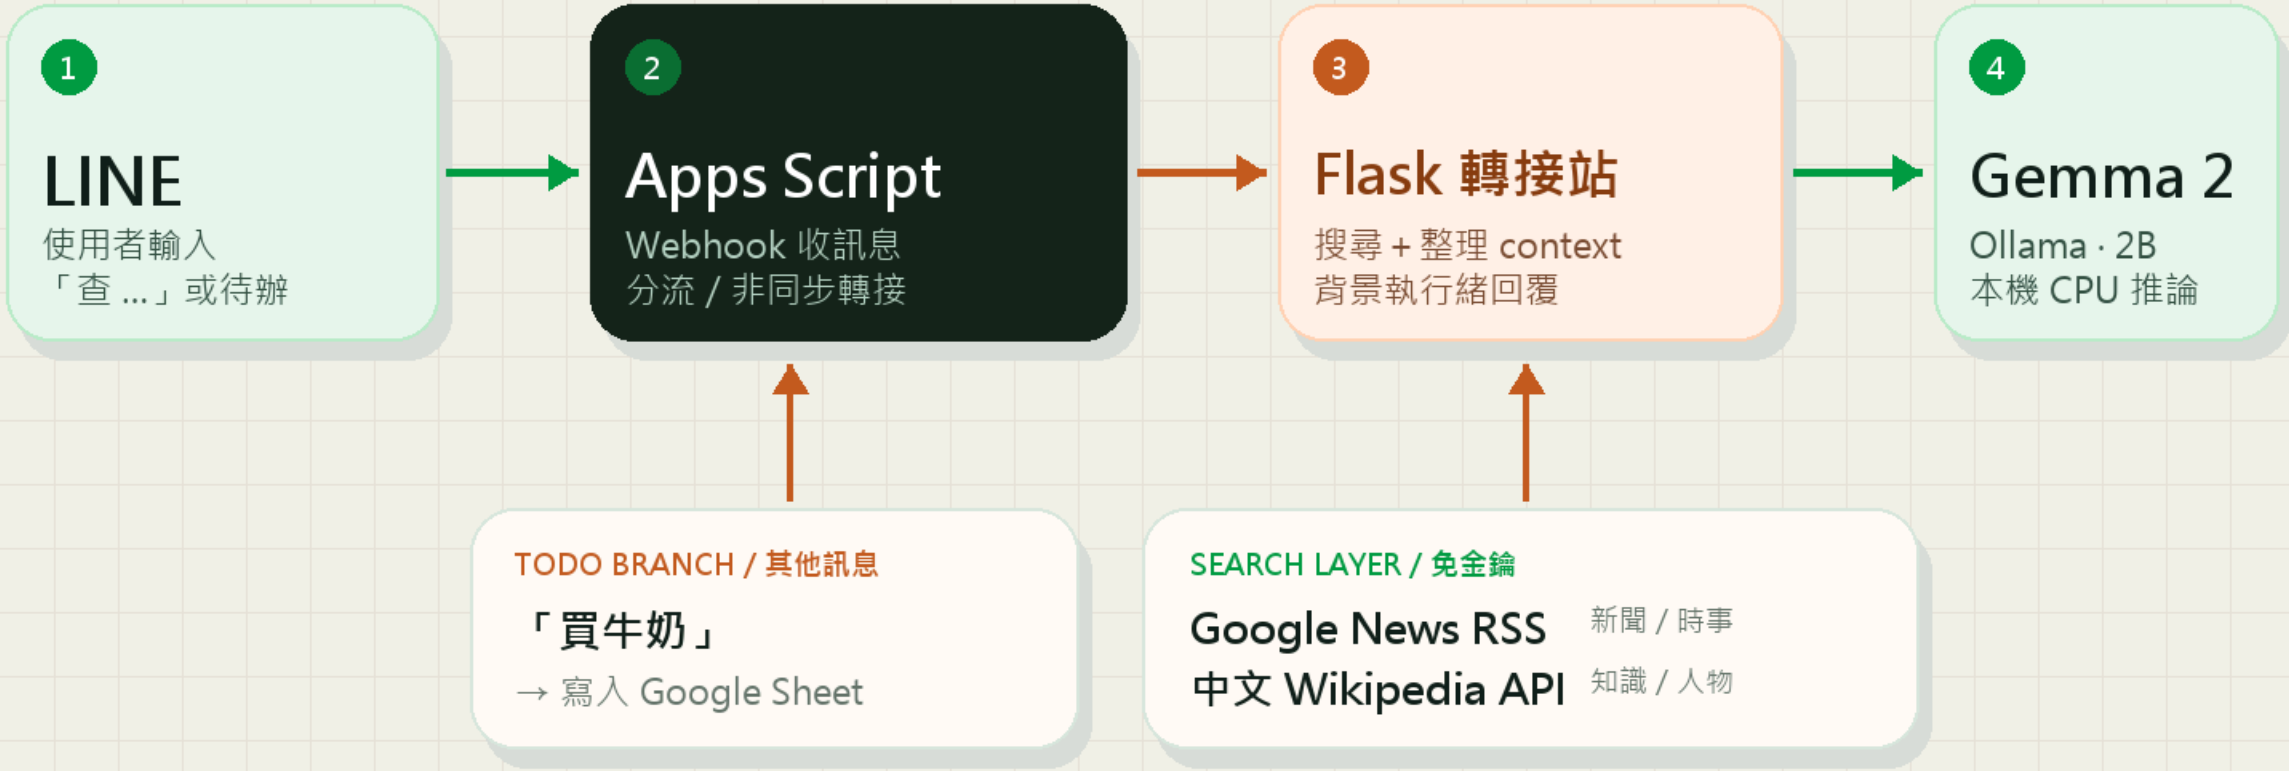
同一套 /ask 流程；展示頁不需要 LINE token。



ARCHITECTURE / 一句話的旅程

# LINE 訊息如何變成有來源的答案？

雲端只負責收發與轉接；搜尋、推論與回覆流程都留在自己的電腦。




**為什麼用 Apps Script？**

不用自己養伺服器，
LINE 驗證與轉接成本最低。

**為什麼用本機模型？**

免逐字計費、資料不送模型商；
代價是電腦要開著。

**為什麼要附來源？**

把「相信我」變成
「你可以自己查」。

03 / ENGINEERING

# 讓它能跑，而不是只看起來能跑。

01

## 非同步 202

Apps Script 先回 200，Flask 算完再直接呼叫 Reply API。

**避免 LINE Webhook 逾時**

02

## 先搜尋，再生成

Google News RSS + Wikipedia，只把前 3 筆放進 prompt。

**答案附來源，降低幻覺**

03

## 2B + 暖機

gemma2:2b、num_predict=220；啟動時先 warm_up()。

**暖機後約 5.9 秒**

04

## 不把祕密寫進程式

本機用環境變數；Apps Script 用指令碼屬性。

**交件前掃描 0 金鑰**

04 / EVIDENCE

# 測試：11/11，沒有僥倖。

**11/11**
**單元測試通過**
不需 LINE token 或 Ollama

**5.9 秒**
**暖機後查詢**
展示頁實測，含搜尋與生成

**16.2 秒**
**冷啟動**
模型載入是主要成本

**0**
**敏感資料**
git 追蹤檔案掃描結果

## 還沒解決的限制

— 電腦要開著；休眠或 Ollama 沒開就查不到

— 只讀 RSS / 摘要，沒有抓文章正文

— ngrok 免費網址會變，換了要更新設定

— Webhook 尚未驗證 LINE 簽章

**LINE 端到端需要 token；交件前以同一個 /ask 流程的展示頁做回歸測試。**

05 / NEXT

# 下一步：從課堂 demo 變成每天可用的工具。

01 **固定網域**
Cloudflare Tunnel 取代會變的 ngrok

02 **Webhook 簽章**
驗證 X-Line-Signature + allowlist

03 **待辦進化**
列表 / 完成 / 刪除，或串 Google Tasks

04 **檢索進化**
抓正文做 RAG + 雲端模型 fallback

90 秒，
讓它跑一次。

# 謝謝

問題與指教歡迎